Chapter 5

Results

5.1 Esecuzioni incluse e provenienza dei risultati

Questo capitolo riporta i risultati della suite `ofat_fixed_thresholds_20261024_211627`, limitatamente alle configurazioni completate su tutti e dodici i dataset: P0, zero-shot; P1, one-shot; P4, few-shot con quattro esempi, identificata come `reference` nei file. La temperatura degli evaluator è 0,3 e la soglia MPNet è 0,68 in tutti e tre i casi. L'analisi comprende quindi **36 run bottom-up**, una per coppia dataset–configurazione, confrontate con le stesse dodici baseline top-down. Non sono incluse medie delle configurazioni di temperatura T0 e T6, che non erano complete sull'intero corpus al momento dello snapshot. RQ2 viene pertanto affrontata qui soltanto per il prompting.

Una run completata viene inclusa anche se termina al limite di 25 iterazioni senza convergere. Non vengono selezionati soltanto gli esiti favorevoli, né usati checkpoint intermedi come risultati finali. La suite registra la policy `cosine_global_documentary_review_v103_conditional_parent_reference_recovery_schema3`. Le modifiche successive al codice non descrivono retroattivamente queste esecuzioni. Lo snapshot dei dati, le metriche, i conteggi e gli estratti dei casi discussi sono conservati in `output/evaluation/thesis_completed_v103_20261025/`. `evidence_manifest.json` registra provenienza e checksum; `case_evidence.json` identifica dataset, configurazione, iterazione, ramo e modello per ciascun estratto.

Le metriche sono state calcolate nuovamente sugli output finali con `bert-base-uncased`, preprocessing NLTK e matching uno-a-uno descritti nel Capitolo 4. Precision, Recall e F1 sono mediate separatamente sui dodici dataset: ogni progetto ha lo stesso peso, indipendentemente dal numero dei suoi goal. I delta sono differenze assolute rispetto alla baseline appaiata, non percentuali. L'analisi descrive una sola ripetizione per configurazione e non stima la variabilità tra generazioni o una significatività statistica.

5.2 Confronto complessivo con il top-down

Tutte e tre le configurazioni aumentano l'F1 medio degli HLG rispetto al top-down: da 0,5297 a 0,5372 con P4, 0,5418 con P0 e 0,5428 con P1. Il vantaggio di P1 su P0 è circa 0,0010 e va letto come differenza descrittiva della singola campagna. Gli incrementi di Precision non coincidono sempre con incrementi di Recall: P0 passa da 0,5794 a 0,6047 in Precision, ma da 0,5725 a 0,5537 in Recall. Una maggiore selettività o una diversa formulazione dei goal può quindi migliorare il matching senza aumentare la copertura misurata dei riferimenti.

Per gli LLG, P0 ottiene l'incremento maggiore: F1 da 0,5083 a 0,5558, con delta +0,0475. La variazione accompagna soprattutto la Recall, che passa da 0,4675 a 0,5135, mentre la Precision cambia da 0,6866 a 0,6883. P4 raggiunge F1 0,5153, con delta +0,0069; P1 rimane

Table 5.1: Metriche semantiche macro degli HLG su tutti i 12 dataset. Ogni riga bottom-up comprende 12 run completate, incluse quelle non convergenti.

Metodo	**Precision**	**Recall**	**F1**	**$\Delta F1$**
Top-down	0,5794	0,5725	0,5297	+0,0000
P0	0,6047	0,5537	0,5418	+0,0121
P1	0,5951	0,5752	0,5428	+0,0131
P4	0,5973	0,5673	0,5372	+0,0075

Table 5.2: Metriche semantiche macro degli LLG su tutti i 12 dataset. Ogni riga bottom-up comprende 12 run completate, incluse quelle non convergenti.

Metodo	**Precision**	**Recall**	**F1**	**$\Delta F1$**
Top-down	0,6866	0,4675	0,5083	+0,0000
P0	0,6883	0,5135	0,5558	+0,0475
P1	0,6815	0,4728	0,5083	-0,0001
P4	0,6830	0,4908	0,5153	+0,0069

sostanzialmente sul valore iniziale, con differenza non arrotondata pari a circa $-0{,}000073$. Non emerge quindi una configurazione uniformemente migliore su entrambi i livelli: P1 ha il maggiore F1 HLG, mentre P0 ha il maggiore F1 LLG.

Questi risultati non dimostrano che introdurre più esempi migliori le prestazioni. P1 contiene un unico scenario con decisioni di mantenimento; P4 aggiunge anche dimostrazioni di riscrittura e rimozione. Il confronto modifica quindi contenuto, copertura delle azioni e lunghezza del prompt, oltre al numero di esempi. Le differenze osservate riguardano queste specifiche configurazioni.

5.3 Risultati per dataset e configurazione

Le Tabelle 5.3–5.5 separano i risultati delle tre configurazioni. AUU indica Assegno Unico Universale; gli altri nomi abbreviati identificano i progetti elencati nel corpus. I conteggi di iterazioni descrivono l'esito operativo, mentre F1 descrive il matching con la ground truth.

Table 5.3: Risultati di P0 per dataset. I delta sono differenze assolute rispetto alla stessa baseline top-down. L'asterisco indica arresto a 25 iterazioni senza convergenza.

Dataset	**HLG F1**	**$\Delta F1_H$**	**LLG F1**	**$\Delta F1_L$**	**Iter.**
AUU	0,5502	+0,1067	0,7255	+0,0020	25*
Calculator	0,5366	+0,0000	0,6083	+0,0000	1
Ethical Purchasing	0,4167	+0,0000	0,5087	+0,0000	1
Event Organization	0,5265	-0,0267	0,6242	+0,2386	4
Fitness Tracker	0,6215	-0,0029	0,6488	+0,0201	10
Genome Nexus	0,5285	-0,0143	0,3510	-0,0115	3
Gestao Hospital	0,6817	+0,0000	0,6199	+0,0000	1
La Reine Marlene	0,4003	+0,0704	0,5208	+0,1286	13
London Ambulance	0,4960	-0,0135	0,4118	-0,0724	6
Planning Poker	0,4965	-0,0182	0,4449	+0,1323	11
Recycling	0,7551	+0,1240	0,5909	+0,0003	5
SIA 25–26	0,4920	-0,0805	0,6153	+0,1320	25

Table 5.4: Risultati di P1 per dataset. I delta sono differenze assolute rispetto alla stessa baseline top-down. L'asterisco indica arresto a 25 iterazioni senza convergenza.

Dataset	**HLG F1**	$\mathbf{\Delta F1_H}$	**LLG F1**	$\mathbf{\Delta F1_L}$	**Iter.**
AUU	0,4776	+0,0341	0,6621	-0,0614	4
Calculator	0,5366	+0,0000	0,6083	+0,0000	1
Ethical Purchasing	0,4167	+0,0000	0,5087	+0,0000	1
Event Organization	0,5532	+0,0000	0,3855	+0,0000	1
Fitness Tracker	0,6244	+0,0000	0,6288	+0,0000	3
Genome Nexus	0,5428	+0,0000	0,3625	+0,0000	1
Gestao Hospital	0,6817	+0,0000	0,6199	+0,0000	1
La Reine Marlene	0,3299	+0,0000	0,3923	+0,0000	1
London Ambulance	0,5176	+0,0080	0,4023	-0,0819	4
Planning Poker	0,4897	-0,0250	0,3687	+0,0561	12
Recycling	0,7524	+0,1213	0,5152	-0,0754	4
SIA 25–26	0,5911	+0,0186	0,6450	+0,1617	4

Table 5.5: Risultati di P4 per dataset. I delta sono differenze assolute rispetto alla stessa baseline top-down. L'asterisco indica arresto a 25 iterazioni senza convergenza.

Dataset	**HLG F1**	$\mathbf{\Delta F1_H}$	**LLG F1**	$\mathbf{\Delta F1_L}$	**Iter.**
AUU	0,4157	-0,0277	0,7526	+0,0291	18
Calculator	0,5366	+0,0000	0,6083	+0,0000	1
Ethical Purchasing	0,4167	+0,0000	0,5087	+0,0000	1
Event Organization	0,5309	-0,0223	0,3917	+0,0062	2
Fitness Tracker	0,6313	+0,0069	0,6338	+0,0050	25*
Genome Nexus	0,5428	+0,0000	0,3625	+0,0000	1
Gestao Hospital	0,6817	+0,0000	0,6199	+0,0000	1
La Reine Marlene	0,3249	-0,0050	0,4913	+0,0991	3
London Ambulance	0,5284	+0,0189	0,2877	-0,1964	13
Planning Poker	0,4781	-0,0366	0,3011	-0,0116	9
Recycling	0,7587	+0,1275	0,5116	-0,0790	7
SIA 25–26	0,6010	+0,0285	0,7142	+0,2309	25*

Gli incrementi aggregati nascondono comportamenti eterogenei. Con P0, l'F1 degli HLG aumenta in tre dataset e diminuisce in sei, restando invariato negli altri tre; i guadagni più ampi di AUU, La Reine Marlene e Recycling compensano le diminuzioni. Per gli LLG della stessa configurazione si osservano sette incrementi, due diminuzioni e tre valori invariati. Con P1, invece, sette dataset mantengono sia il valore HLG sia quello LLG della baseline: il maggiore F1 HLG medio non implica una revisione estesa di tutti i progetti.

Recycling mostra il disaccoppiamento tra livelli: con P4 l'F1 HLG passa da 0,6311 a 0,7586, mentre l'F1 LLG scende da 0,5906 a 0,5116. Il miglioramento del padre non garantisce quindi una decomposizione migliore. Anche London Ambulance Service converge con P4 dopo tredici iterazioni, ma l'F1 LLG diminuisce da 0,4841 a 0,2877. Viceversa, in Event Organization P0 aumenta l'F1 LLG da 0,3855 a 0,6242, pur riducendo l'F1 HLG da 0,5532 a 0,5265. Le due misure devono essere interpretate separatamente.

5.4 Convergenza, decisioni e costo iterativo

Table 5.6: Esiti operativi delle 36 run: convergenza, cicli globali e passaggi di riparazione della collezione. Le rimozioni contano rami effettivamente eliminati, anche se altri goal sono generati in seguito.

	Conv.	**Cicli**	**Media**	**Rip. acc.**	**Rip. rif.**	**Rimossi**
P0	11/12	105	8,75	83	9	6
P1	12/12	37	3,08	20	2	2
P4	10/12	106	8,83	86	8	9

P1 converge su tutti i dodici dataset in 37 iterazioni globali complessive; P0 converge su undici dataset e ne richiede 105; P4 converge su dieci e ne richiede 106. Le medie sono rispettivamente 3,08, 8,75 e 8,83 iterazioni per dataset. Questi conteggi indicano lavoro iterativo e non tempi di esecuzione: la durata dipende anche da dimensione dei prompt, tentativi locali e caricamento dei modelli. AUU non converge con P0 entro 25 iterazioni; Fitness Tracker e SIA 25–26 non convergono con P4. SIA 25–26 converge invece all'ultima iterazione consentita con P0.

Table 5.7: Decisioni aggregate per ramo, sommate su tutte le iterazioni. DUP indica DUPLICATE_REMOVAL; INC indica un esito inconcludente del software, non un'azione LLM.

	KEEP	**REWRITE**	**REMOVE**	**DUP**	**INC**
P0	360	223	0	6	17
P1	140	42	0	2	3
P4	438	232	2	7	17

Le decisioni della Tabella 5.7 sono conteggi di rami esaminati attraverso tutte le iterazioni, non di goal distinti. Una riscrittura approvata può produrre un passaggio di riparazione rifiutato; più rami riscritti nella stessa iterazione condividono un solo passaggio top-down. Per questo i 232 voti aggregati di riscrittura di P4 corrispondono a 86 passaggi accettati e otto rifiutati, non a 232 chiamate indipendenti alla pipeline.

Nell'ultima iterazione delle tre run non convergenti, AUU con P0 mantiene tre rami e richiede quattro riscritture; Fitness Tracker con P4 mantiene due rami, richiede due riscritture e lascia un ramo inconcludente; SIA 25–26 con P4 mantiene cinque rami e richiede tre riscritture. Le altre 33 run terminano con tutti i rami confermati. Questi esiti conclusivi sono distinti dai totali dell'intero percorso nella Tabella 5.7.

Gli evaluator forniscono 318 risposte globali valide in P4, 312 valide e tre non valide in P0, 110 valide e una non valida in P1. Questi conteggi riguardano l'esito finale del budget di tentativi di ciascun modello per iterazione, non tutti i tentativi tecnici. La maggior parte degli output rispetta dunque il contratto JSON; la validità strutturale non garantisce però la compatibilità delle critiche o la correttezza documentale della decisione.

Table 5.8: Proposte individuali nelle risposte globali valide, sommate sui dodici dataset. Le ultime colonne contano risposte globali valide (V) e non valide (NV), non decisioni per ramo.

	Modello	KEEP	REWRITE	REMOVE	DUP	V	NV
P0	Ministral	337	245	15	8	105	0
P0	Granite	551	46	2	6	105	0
P0	Gemma	329	243	6	11	102	3
P1	Ministral	127	53	2	4	37	0
P1	Granite	179	5	0	2	37	0
P1	Gemma	103	72	0	6	36	1
P4	Ministral	386	280	7	19	106	0
P4	Granite	517	147	24	4	106	0
P4	Gemma	442	229	3	18	106	0

I modelli non utilizzano le azioni con la stessa frequenza. In P1, Granite propone 179 mantenimenti e cinque riscritture, Ministral 127 mantenimenti e 53 riscritture, Gemma 103 mantenimenti e 72 riscritture. La stessa informazione non conduce quindi a giudizi uniformi. Questi conteggi non misurano l'accuratezza dei singoli evaluator: descrivono il loro comportamento sulle gerarchie effettivamente visitate. I confronti tra configurazioni dipendono anche dal numero diverso di iterazioni e rami esaminati. Il dettaglio per modello, dataset e configurazione, insieme alle decisioni aggregate dell'intera run e dell'ultima iterazione, rimane nei CSV dell'analisi.

5.5 Casi reali: contributi utili e limiti

Gli esempi seguenti sono estratti dagli output effettivamente salvati, non dalle dimostrazioni few-shot. I listing riproducono la singola decisione selezionata dentro una risposta globale più ampia. Il numero del ramo vale esclusivamente nello snapshot indicato.

5.5.1 Recupero di capacità documentate: Event Organization, P0

Alla prima iterazione, il ramo 1 ha come padre *Manage Event Planning and Coordination*, la cui descrizione menziona inviti, prenotazione dei servizi e budget. La ricostruzione è *Manage event planning and financial oversight from setup to execution.* Il documento fornito ai modelli descrive anche la richiesta di appuntamenti ai fornitori e l'accettazione o il rifiuto dei preventivi, capacità non esplicite nella descrizione iniziale del padre. Ministral produce l'estratto seguente; Gemma propone anch'esso REWRITE, mentre Granite propone KEEP.

```
{
  "branch_id": "1",
  "decision": "REWRITE_ORIGINAL_HIGH_LEVEL_GOAL",
  "feedback": {
    "critique": "Manage Event Planning and Coordination. Preserve the scope of guest invitations,
    service bookings, and budget tracking. Change to explicitly include appointment scheduling and
     quotation management, aligning with actor responsibility."
  }
}
```

Listing 5.1: Decisione reale di Ministral: Event Organization, P0, iterazione 1, ramo 1.

Nella gerarchia finale compaiono, tra gli altri, i goal *Manage Quotations and Approvals*, descritto come la possibilità di visualizzare, approvare o rifiutare preventivi, e *Manage Payment Schedules for Event Services*, che include rate, anticipo e saldo. Entrambi hanno un riscontro esplicito nella descrizione del progetto usata dalla pipeline. Gli LLG passano da 10 a 22 su 28 riferimenti; la Recall semantica sale da 0,2616 a 0,5573 e la Precision diminuisce da 0,7325 a 0,7093. Il guadagno F1 osservato è quindi coerente con una maggiore copertura testuale accompagnata da una lieve perdita di Precision. La riscrittura riapre la decomposizione e rende possibile tale recupero; il caso non isola il contributo causale di HLG$'$ rispetto alla rigenerazione completa degli LLG e agli altri segnali disponibili.

5.5.2 Conservazione della baseline: Calculator

Calculator termina alla prima iterazione in tutte e tre le configurazioni, confermando l'unico HLG *Enable quick and accurate basic arithmetic operations*. La collezione rimane composta da un HLG e cinque LLG, con F1 HLG 0,5366 e F1 LLG 0,6083 invariati. Il meccanismo evita una rigenerazione in questo caso, ma l'accordo dei modelli non rende perfetta la baseline rispetto ai riferimenti. La conservazione costituisce un esito utile di stabilità, distinto da un miglioramento delle metriche.

5.5.3 Critiche incompatibili: Fitness Tracker, P4

All'iterazione 25, il ramo 2 riguarda *Support users in setting and achieving personalized fitness goals*. Il padre consente già di definire obiettivi misurabili con scadenze, usare dati storici, monitorare il progresso e ricevere feedback e promemoria. HLG$'$ sintetizza obiettivi definiti, visualizzazione dei progressi e promemoria. Ministral e Granite approvano entrambi REWRITE, ma forniscono istruzioni divergenti:


```
{
  "branch_id": "2",
  "decision": "REWRITE_ORIGINAL_HIGH_LEVEL_GOAL",
  "feedback": {
    "critique": "For the goal 'Support users in setting and achieving personalized fitness goals':
     The original scope is overly broad for Fitness Enthusiasts; correct to focus solely on
     tracking progress, visual feedback, and reminders without defining objectives or deadlines."
  }
}
```


Listing 5.2: Decisione reale di Ministral: Fitness Tracker, P4, iterazione 25, ramo 2.


```
{
  "branch_id": "2",
  "decision": "REWRITE_ORIGINAL_HIGH_LEVEL_GOAL",
  "feedback": {
    "critique": "For the goal 'Support users in setting and achieving personalized fitness goals':
     The original description lacks clarity on how historical performance data is utilized for goal
      definition and progress monitoring. Rewrite to specify that this feature will use historical
     workout data to set measurable objectives, track progress, and provide visual feedback and
     reminders."
  }
}
```


Listing 5.3: Decisione reale di Granite sullo stesso ramo e snapshot.

La prima critica esclude la definizione di obiettivi e scadenze; la seconda chiede di esplicitare l'uso dei dati storici per definire gli obiettivi, già presente nel padre corrente. Gemma propone KEEP. I due voti di riscrittura raggiungono il quorum, ma non esprimono accordo sul contenuto della correzione. La concatenazione trasferisce entrambe le istruzioni al generatore. Questa incompatibilità fornisce una spiegazione plausibile delle revisioni persistenti,

senza dimostrare da sola la causa di tutte le oscillazioni. La run termina senza convergenza, con due riscritture e un ramo inconcludente nell'ultimo snapshot; gli incrementi F1 rispetto alla baseline sono soltanto +0,0069 per gli HLG e +0,0050 per gli LLG.

5.5.4 Una duplicazione approvata non garantisce copertura: AUU, P1

Alla prima iterazione, tutti e tre gli evaluator chiedono di eliminare il ramo 8, *Support application modifications and additions after submission*, come duplicato del ramo 3, *Enable real-time fiscal code validation and conflict detection.* L'output di Ministral è il seguente; gli altri due modelli indicano la stessa coppia di identificativi.

```
{
  "branch_id": "8",
  "decision": "DUPLICATE_REMOVAL",
  "surviving_branch_id": "3"
}
```

Listing 5.4: Decisione reale di Ministral: AUU, P1, iterazione 1, ramo 8; voto unanime dei tre evaluator.

Il primo padre descrive l'aggiunta di figli a domande esistenti e la modifica dei dati di pagamento o delle dichiarazioni; il superstite descrive la validazione dei codici fiscali e il blocco delle domande in conflitto. I testi condividono una parte delle funzionalità, ma il secondo non esplicita tutte quelle del primo. La descrizione del progetto richiede espressamente di aggiungere figli a una domanda esistente e confermare o modificare i dati già presenti. Il codice applica `REMOVED_WITH_CHILDREN`; negli HLG finali non compare più una formulazione esplicita dell'aggiunta di figli. Questo è un caso in cui l'unanimità non dimostra la copertura completa necessaria alla rimozione. L'analisi riguarda il testo conservato e non costituisce una verifica formale di tutta la gerarchia. La run converge in quattro iterazioni e migliora F1 HLG di +0,0341, ma riduce F1 LLG di −0,0614: convergenza e miglioramento del matching degli HLG possono coesistere con una perdita agli altri livelli.

5.5.5 Granularità e dettagli non supportati: London e Recycling, P4

In London Ambulance Service gli LLG passano da sei a dodici, a fronte di tre riferimenti. La Precision scende da 0,3631 a 0,1798, mentre la Recall passa da 0,7262 a 0,7194. Poiché il matching è uno-a-uno, al massimo tre goal generati contribuiscono alla somma assegnata; gli altri aumentano il denominatore della Precision. La crescita del numero dei goal non si traduce quindi in maggiore copertura misurata. Tra gli output finali compare *Load real-time traffic data for current route*, mentre la descrizione fornita richiede il raggiungimento entro undici minuti, l'allocazione dei veicoli e l'aderenza a percorsi standard, senza specificare un servizio di traffico in tempo reale.

In Recycling la descrizione richiede sicurezza dei dati in termini generali, ma la decomposizione finale contiene *System uses AES-256 encryption for data at rest and TLS 1.3 for data in transit.* Queste specifiche tecniche non compaiono nel testo del progetto usato dai modelli. Inoltre, tra gli LLG finali non sono espliciti la mappa e le notifiche degli eventi, citate nella descrizione. Il miglioramento F1 HLG di +0,1275 non equivale pertanto a una correzione completa della gerarchia. La revisione usa le sintesi HLG$'$ e non i testi integrali degli LLG: questo limita la visibilità dei dettagli introdotti o omessi durante la decomposizione.

5.6 Interpretazione rispetto alle domande di ricerca

Per RQ1, l'estensione produce incrementi medi di F1 HLG in tutte le configurazioni complete e incrementi F1 LLG in P0 e P4, mentre P1 mantiene sostanzialmente il valore LLG iniziale. I risultati per dataset mostrano miglioramenti, conservazioni e peggioramenti: l'effetto del feedback dipende dal progetto e dal livello considerato. Il meccanismo funziona in modo utile quando conserva una gerarchia senza richiedere revisioni o quando una critica documentata riapre una decomposizione incompleta. Mostra invece limiti nei conflitti tra critiche, nelle rimozioni di funzionalità complementari e nelle decomposizioni che introducono granularità o dettagli non supportati.

Per la parte di RQ2 dedicata al prompting, P1 presenta la maggiore stabilità operativa e P0 il maggiore F1 LLG. Il minor numero di revisioni con P1 è compatibile con un comportamento più conservativo e con il contenuto del suo esempio, che mostra mantenimenti; questa è un'interpretazione, non un effetto causale isolato dal disegno. I risultati non sostengono una superiorità generale del few-shot. Non viene formulata una conclusione sulla temperatura, poiché T0 e T6 non fanno parte del confronto completo qui congelato.

Le spiegazioni restano limitate da una sola ripetizione, dal matching testuale che non valuta direttamente attori e associazioni padre–figlio, e dal riuso della generazione top-down dell'intera collezione durante le riparazioni. La convergenza misura l'accordo operativo finale, non la correttezza dei requisiti. Questi limiti spiegano perché occorre leggere metriche e tracce insieme e perché un singolo F1 aggregato non basta a stabilire dove la gerarchia sia stata corretta.